

Anwendung von Machine Learning für SmartHome

DBE25-Artificial Intelligence

Gruppe 4

Hatun-Nur Karaca, 814149

Jan Müller, 816574

Selcuk Balikci, 813401

Liv Rottler, 816652

Nuri Saracoglu, 814492

Glen Braun, 816364



Agenda

- 1 Unternehmensbeschreibung
- 2 Problem- und Fragestellung
- 3 Vorbereitung Datensatz
- 4 Auswahl / Ergebnisse der Modellierungsarten
- 5 Einsatz im Unternehmen
- 6 Recommendation

Unternehmensbeschreibung

BSH Hausgeräte GmbH,

-
- ✓ Hauptsitz: München, Deutschland
 - Gründung: 1967
 - Industrie: Haushaltsgeräte / Smart Home



Geschäftsziele

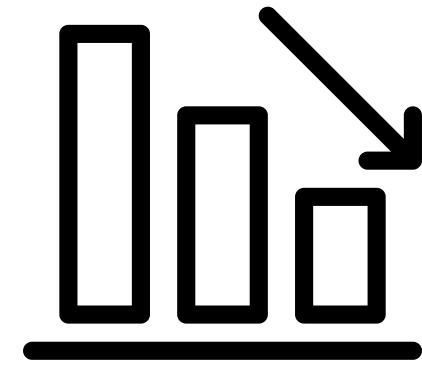
- Führender Anbieter für vernetzte und nachhaltige Haushaltslösungen
- Stärkung digitaler Services über Home Connect
- Datengetriebene Entscheidungsfindung & Personalisierung der Nutzererfahrung



Fokus und Werte

- Nachhaltigkeit durch energieeffiziente Technologien
- Nutzerzentrierung & intuitive Bedienbarkeit
- Innovation durch KI & IoT für das smarte Zuhause

Problem und Fragestellung



Unklare Kaufbereitschaft

Fehlende Zufriedenheitsprognose

Keine systematische Segmentierung

Unbekannte Gerätetreiber

Fehlende datenbasierte
Entscheidungsgrundlagen

Problem und Fragestellung



Kaufverhalten analysieren

- Wer tätigt In-App-Käufe?
- Wie lassen sich kaufbereite Haushalte erkennen?



Kunden (Un)zufriedenheit verstehen

- Welche Faktoren beeinflussen die Nutzerzufriedenheit?
- Gibt es Unterschiede zwischen Nutzergruppen?



Kundensegmentierung ermöglichen

- Wie lassen sich Haushalte sinnvoll in Segmente unterteilen?
- Welche Zielgruppen lassen sich datenbasiert identifizieren?



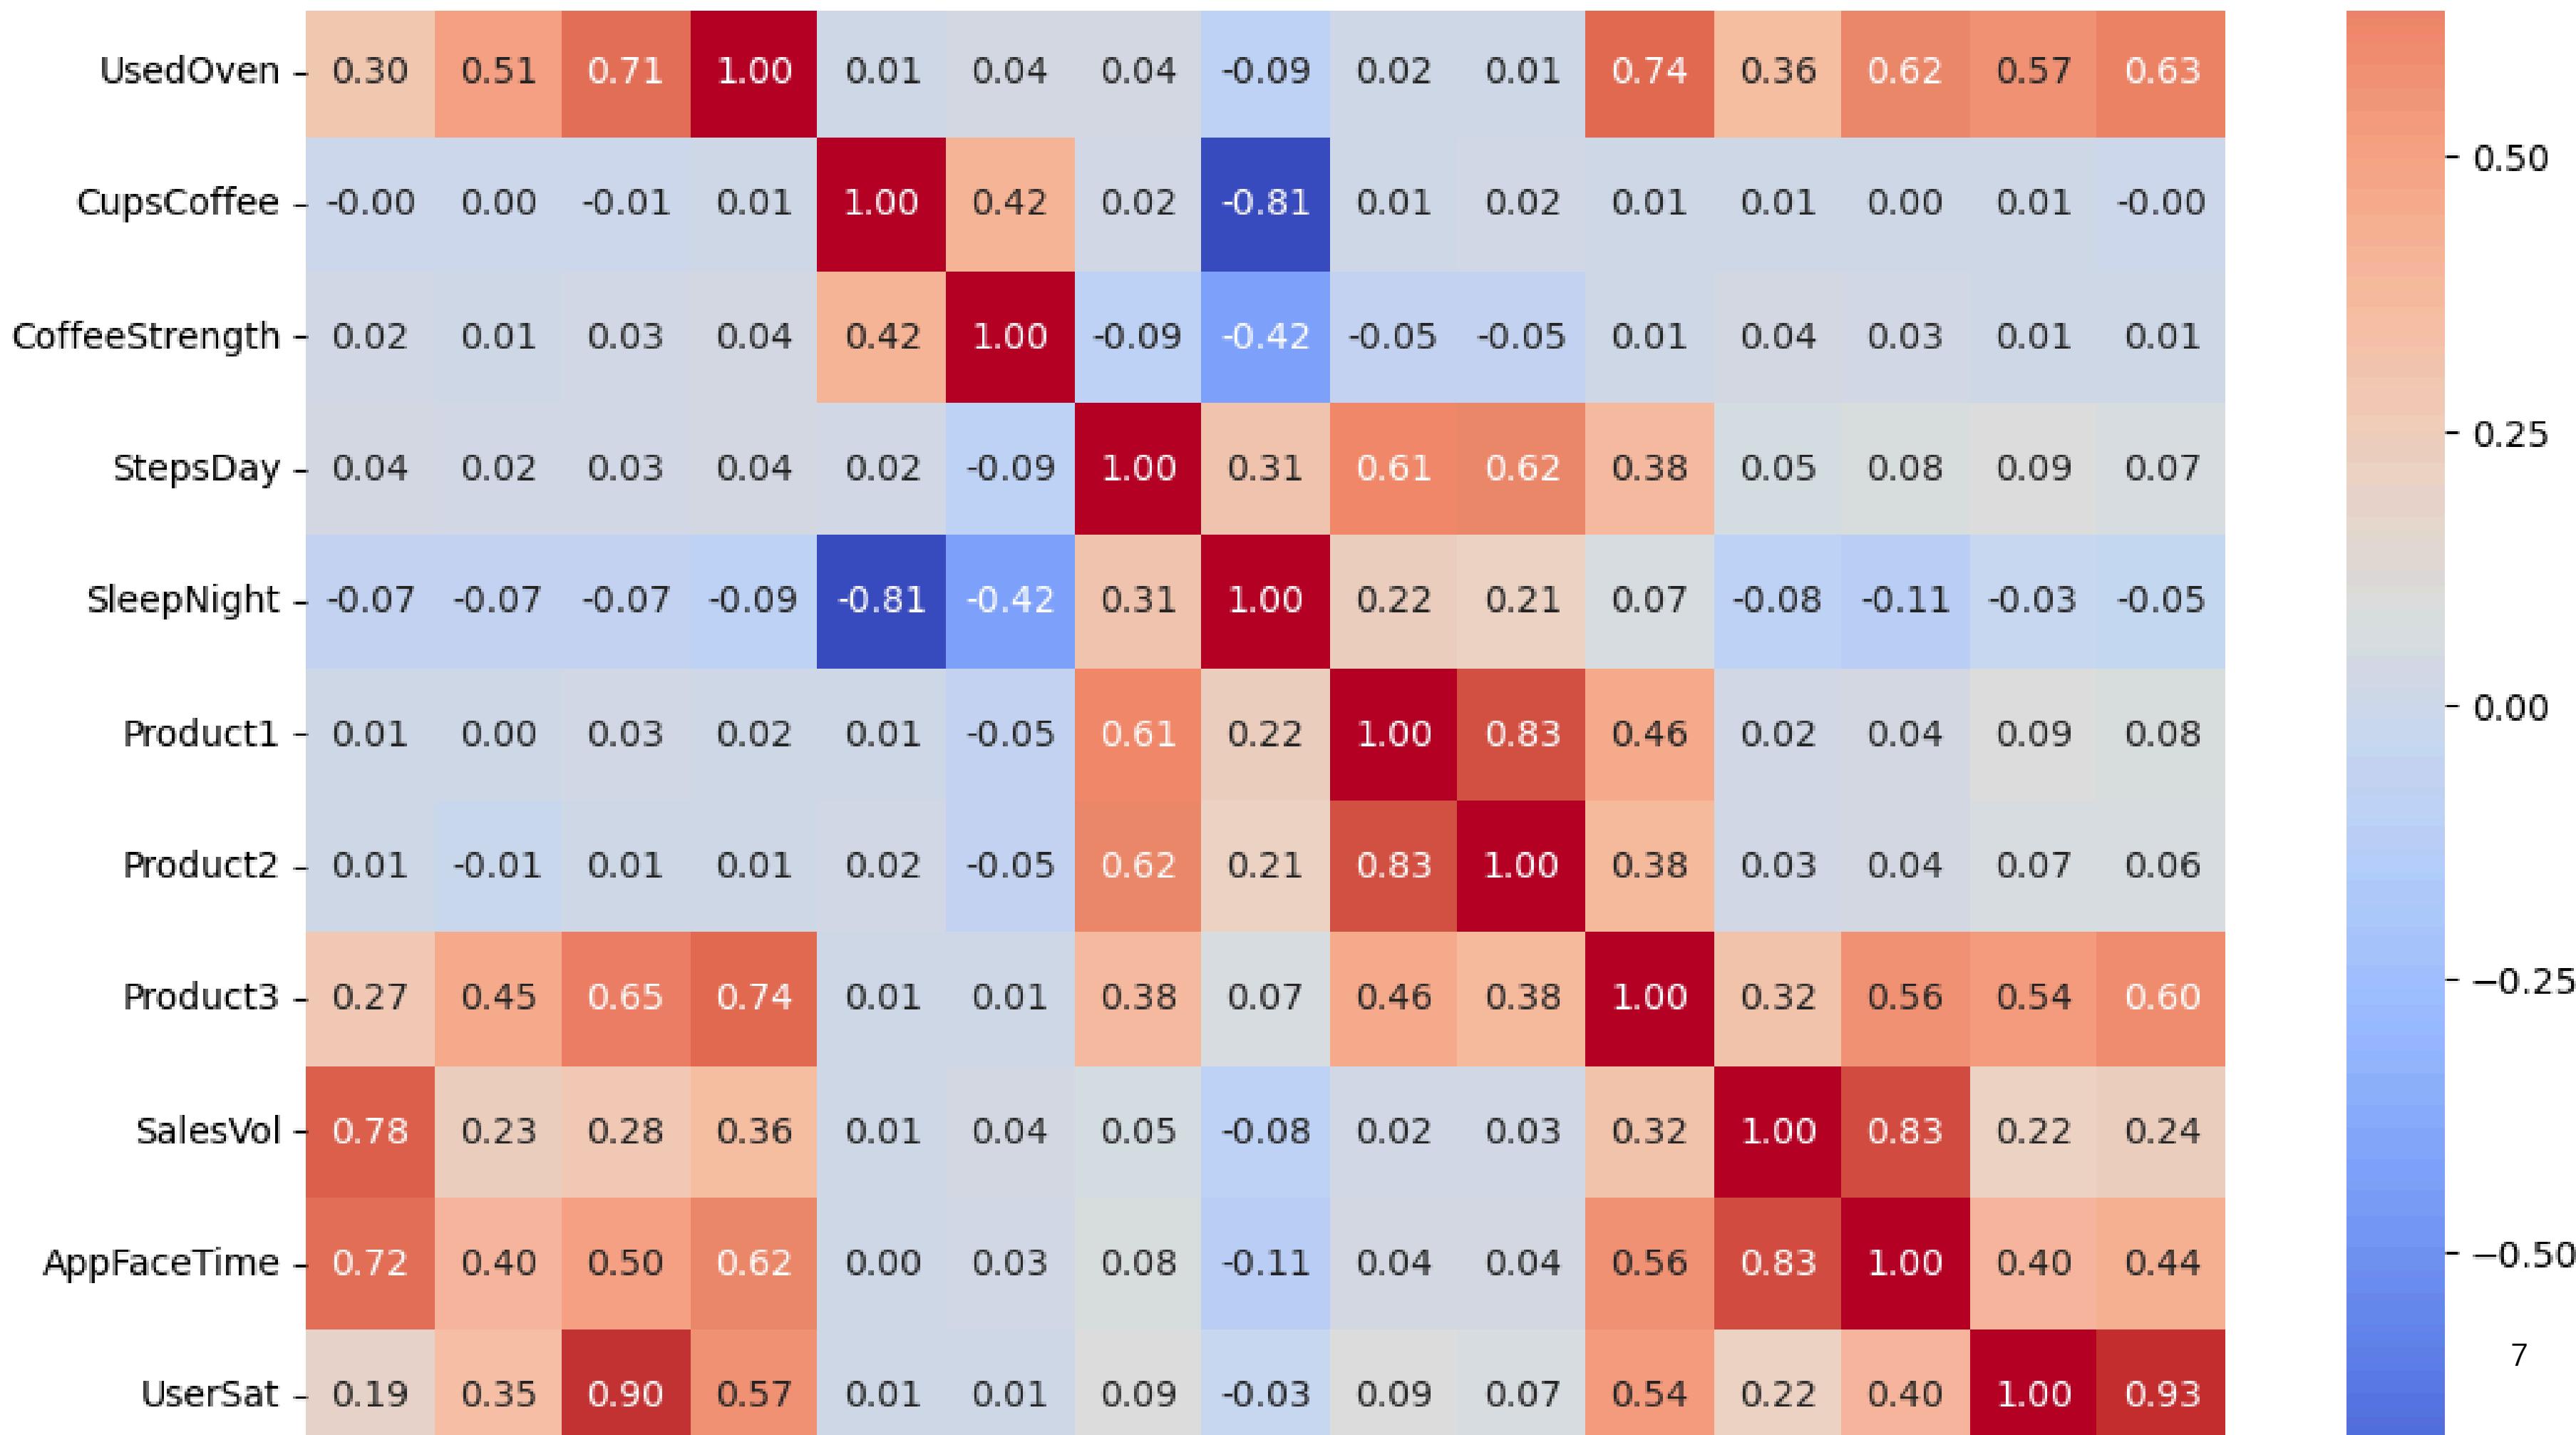
Digitale Serviceentwicklung vorantreiben

- Welche Features oder Services sind für welche Nutzergruppen sinnvoll?
- Wie können wir datenbasiert personalisierte Empfehlungen ableiten?

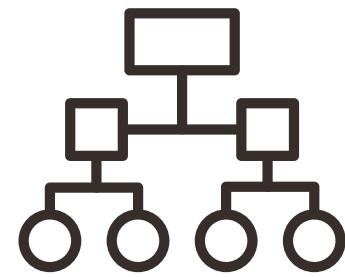
Vorbereitung des Datensatzes



- Datenverteilung analysiert und Ausreisser erkannt
- Nullwerte identifiziert und bereinigt
- Fehlerhafte oder unplausible Einträge bereinigt auf Basis des Data Dictionary
- Ausreißer identifiziert und bereinigt
- Korrelation mittels Heatmap visualisiert
- Variable In App Purchase binär kodiert
- Kategoriale Variablen (Region, Wetter) mittels One Hot Encoding transformiert



Auswahl der Modellierungsarten



Klassifikation

Vorhersage von In App Käufe

Zielvariable: In App, Purchase (Yes/No) / SalesVol
Business Frage: Welche Haushalte sind kaufbereit?

Nutzen: Targeting für Marketingaktionen

Ergebnisse der 1. Klassifikation

Zielvariable: InAppPurchase

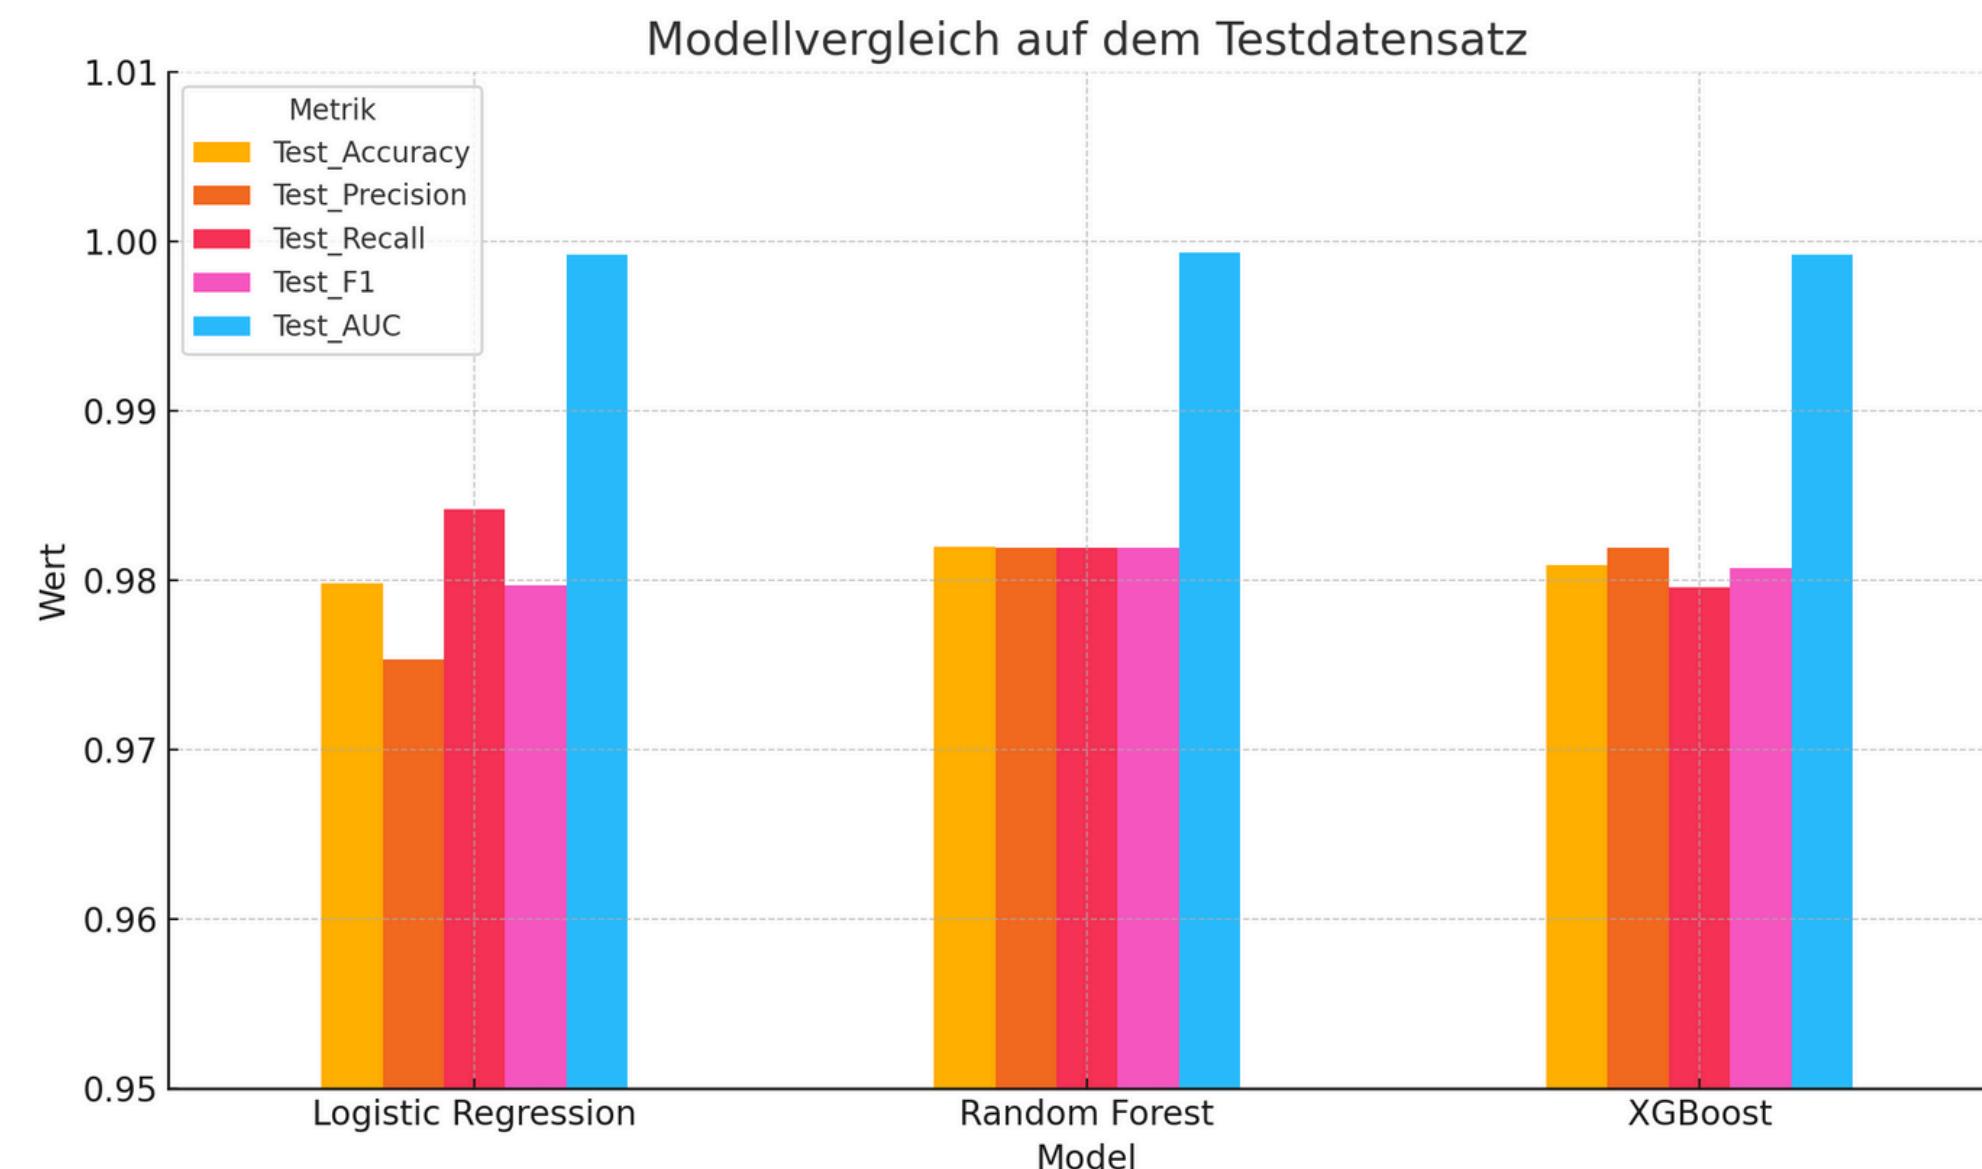
Features: 'Individuals', 'Adults', 'UsedOven', 'CupsCoffee', 'CoffeeStrength',
'StepsDay', 'SleepNight', 'Product1', 'Product2', 'Product3'

Modell	Fazit
Logistic Regression	Sehr gute Basisleistung (F1: 0.96), fast so gut wie die komplexeren Modelle. Recall sehr hoch (gut für Käufererkennung)
Random Forest	Ähnlich gut wie Logistic, aber etwas schlechter bei AUC & F1 – robustes Modell
XGBoost	Bestes Modell insgesamt: höchste Accuracy, AUC und F1 – am besten für Klassifikation geeignet

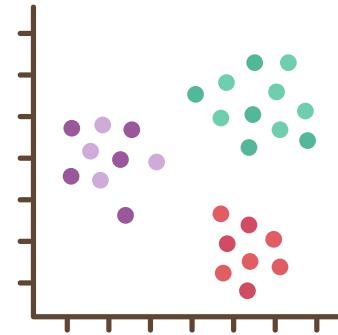
Ergebnisse der 2. Klassifikation

Zielvariable: SalesVol

Features: 'AppFaceTime', 'Individuals', 'InAppPurchase', 'UsedOven', 'Product3', 'Region_NL',
'Adults', 'UserSat', 'Region_UK', 'Weather_Sunny', 'Weather_Rainy'



Auswahl der Modellierungsarten



Clustering

Customer Segmentation

Business Frage: Wie können die Haushalte segmentiert werden, um sie gezielt anzusprechen

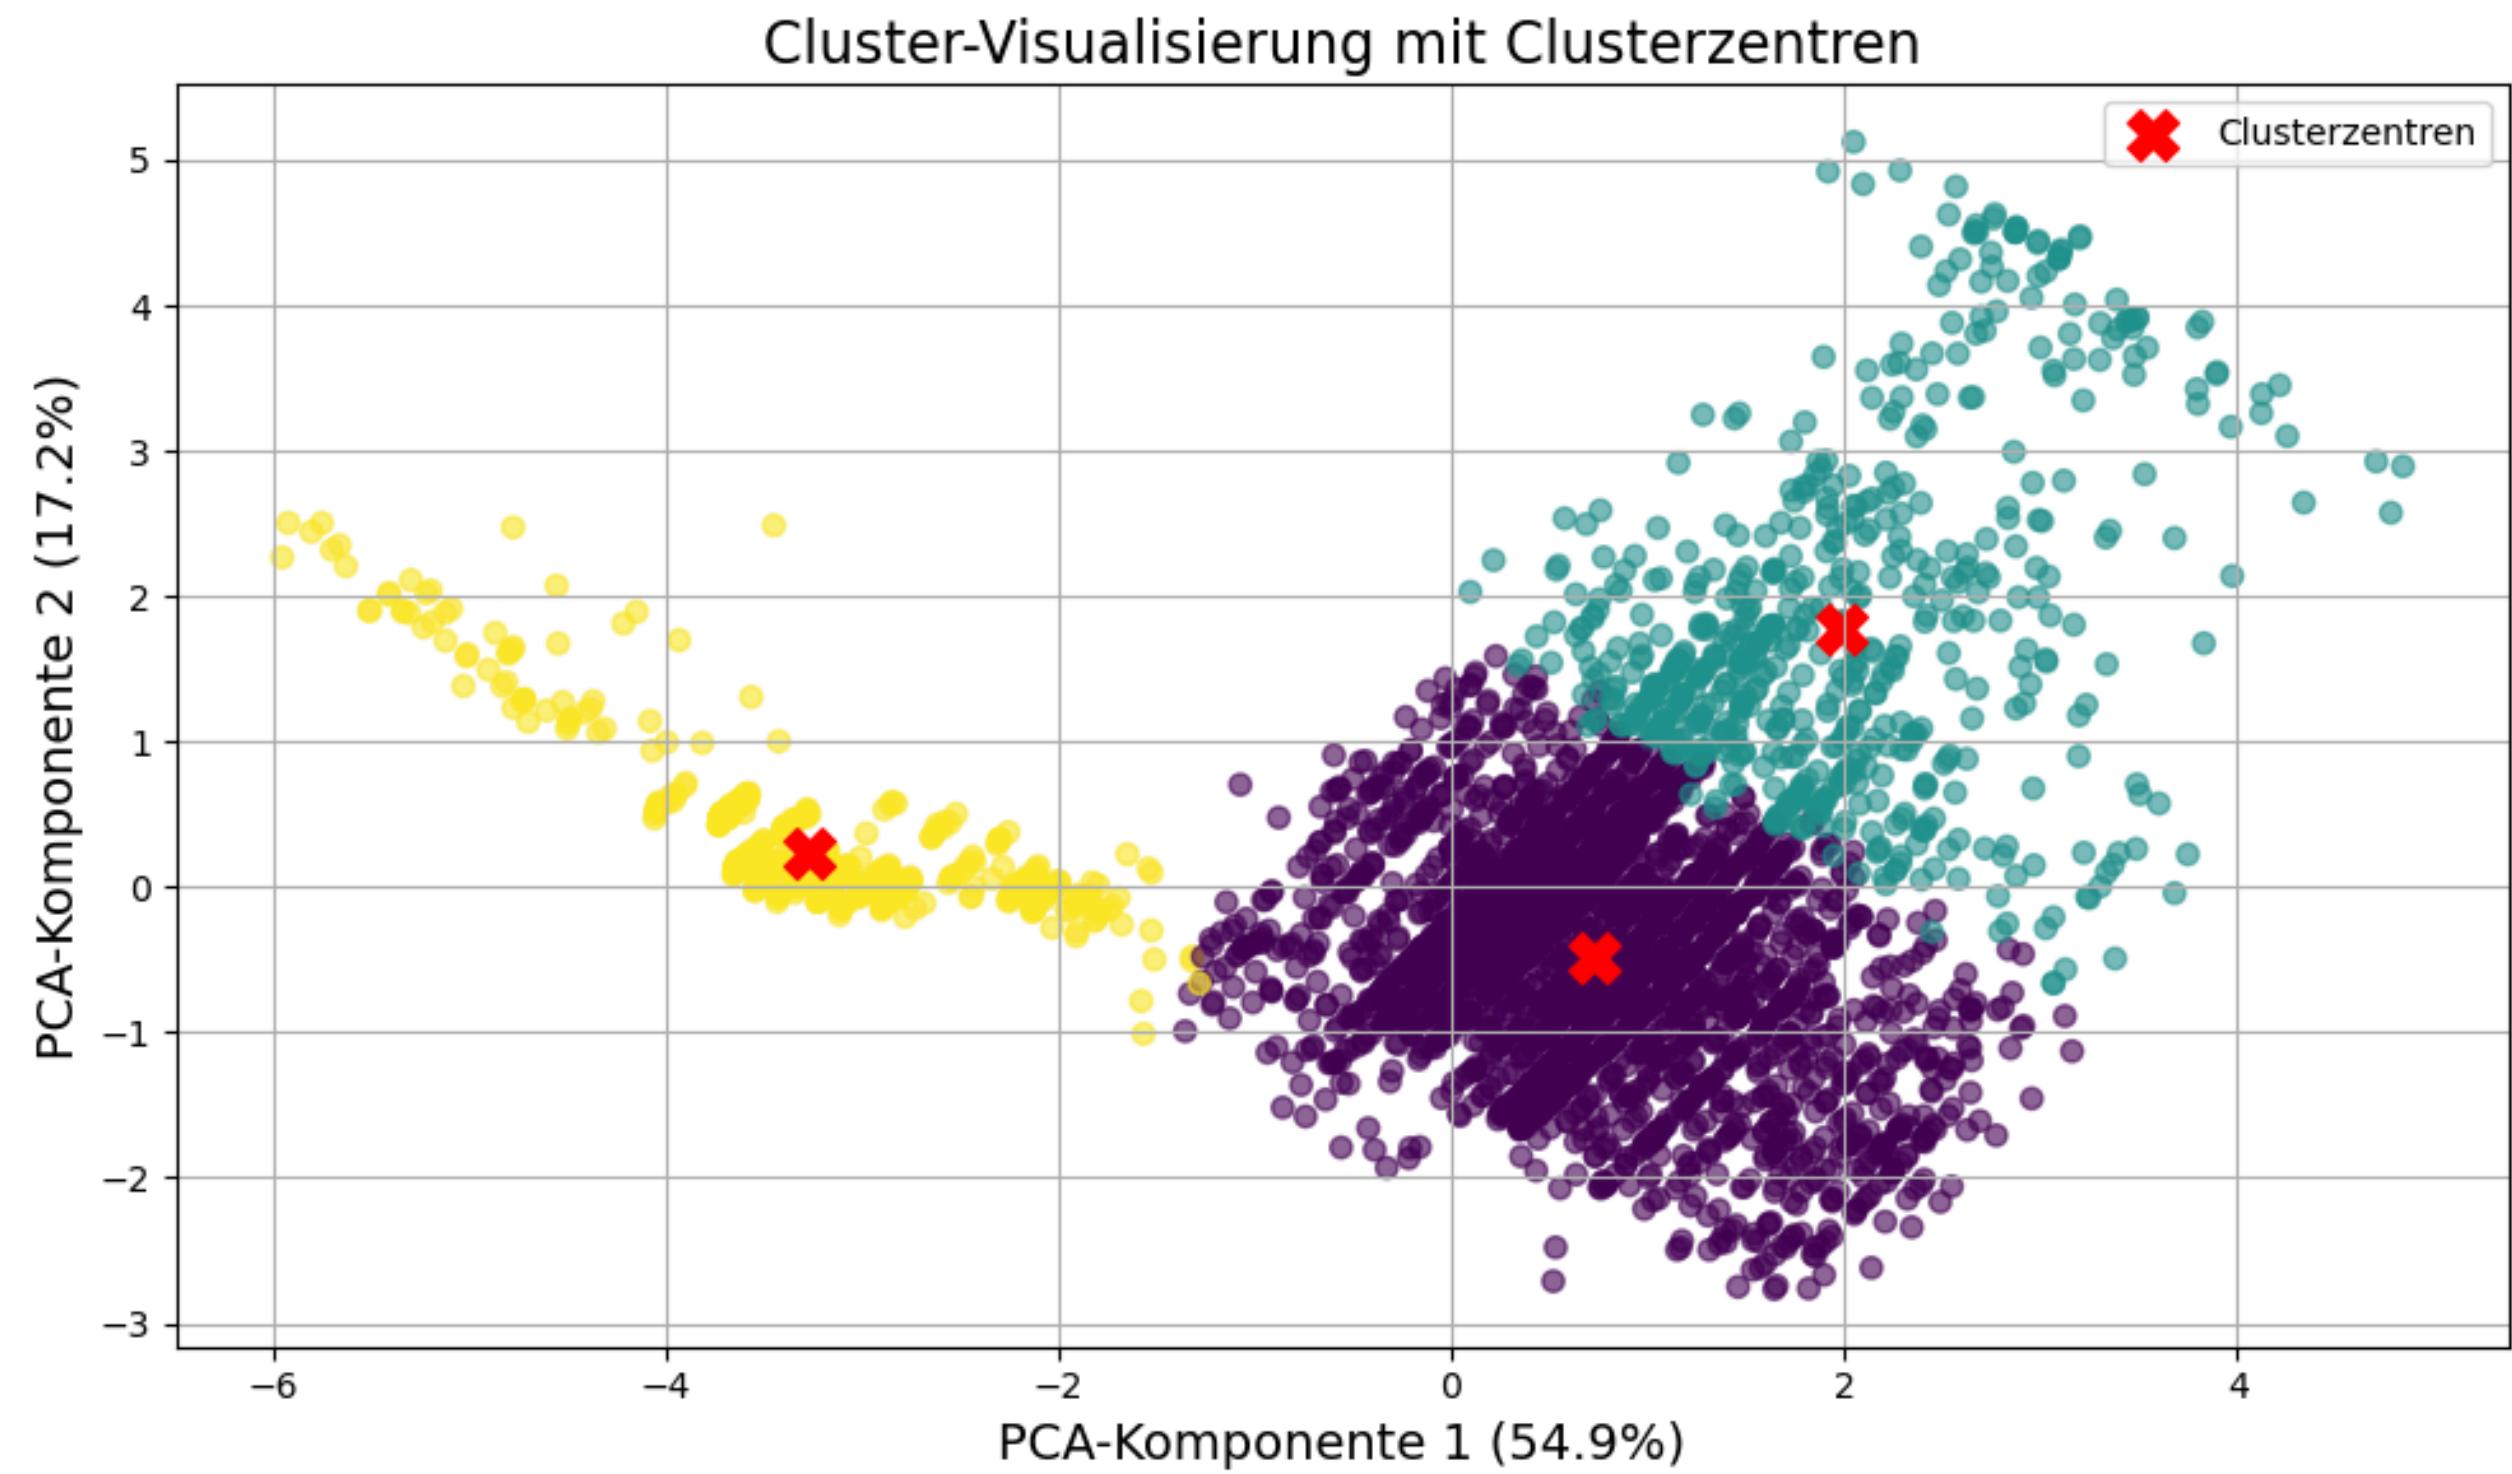
Nutzen: Marketing und Service Strategien zielgerichtet auf unterschiedliche Gruppen zuschneiden

Ausgewählte Features: 'OpenFridge', 'UsedOven', 'CupsCoffee', 'AppFaceTime', 'InAppPurchase', 'SalesVol', 'UserSat'

Ergebnisse des Clustering

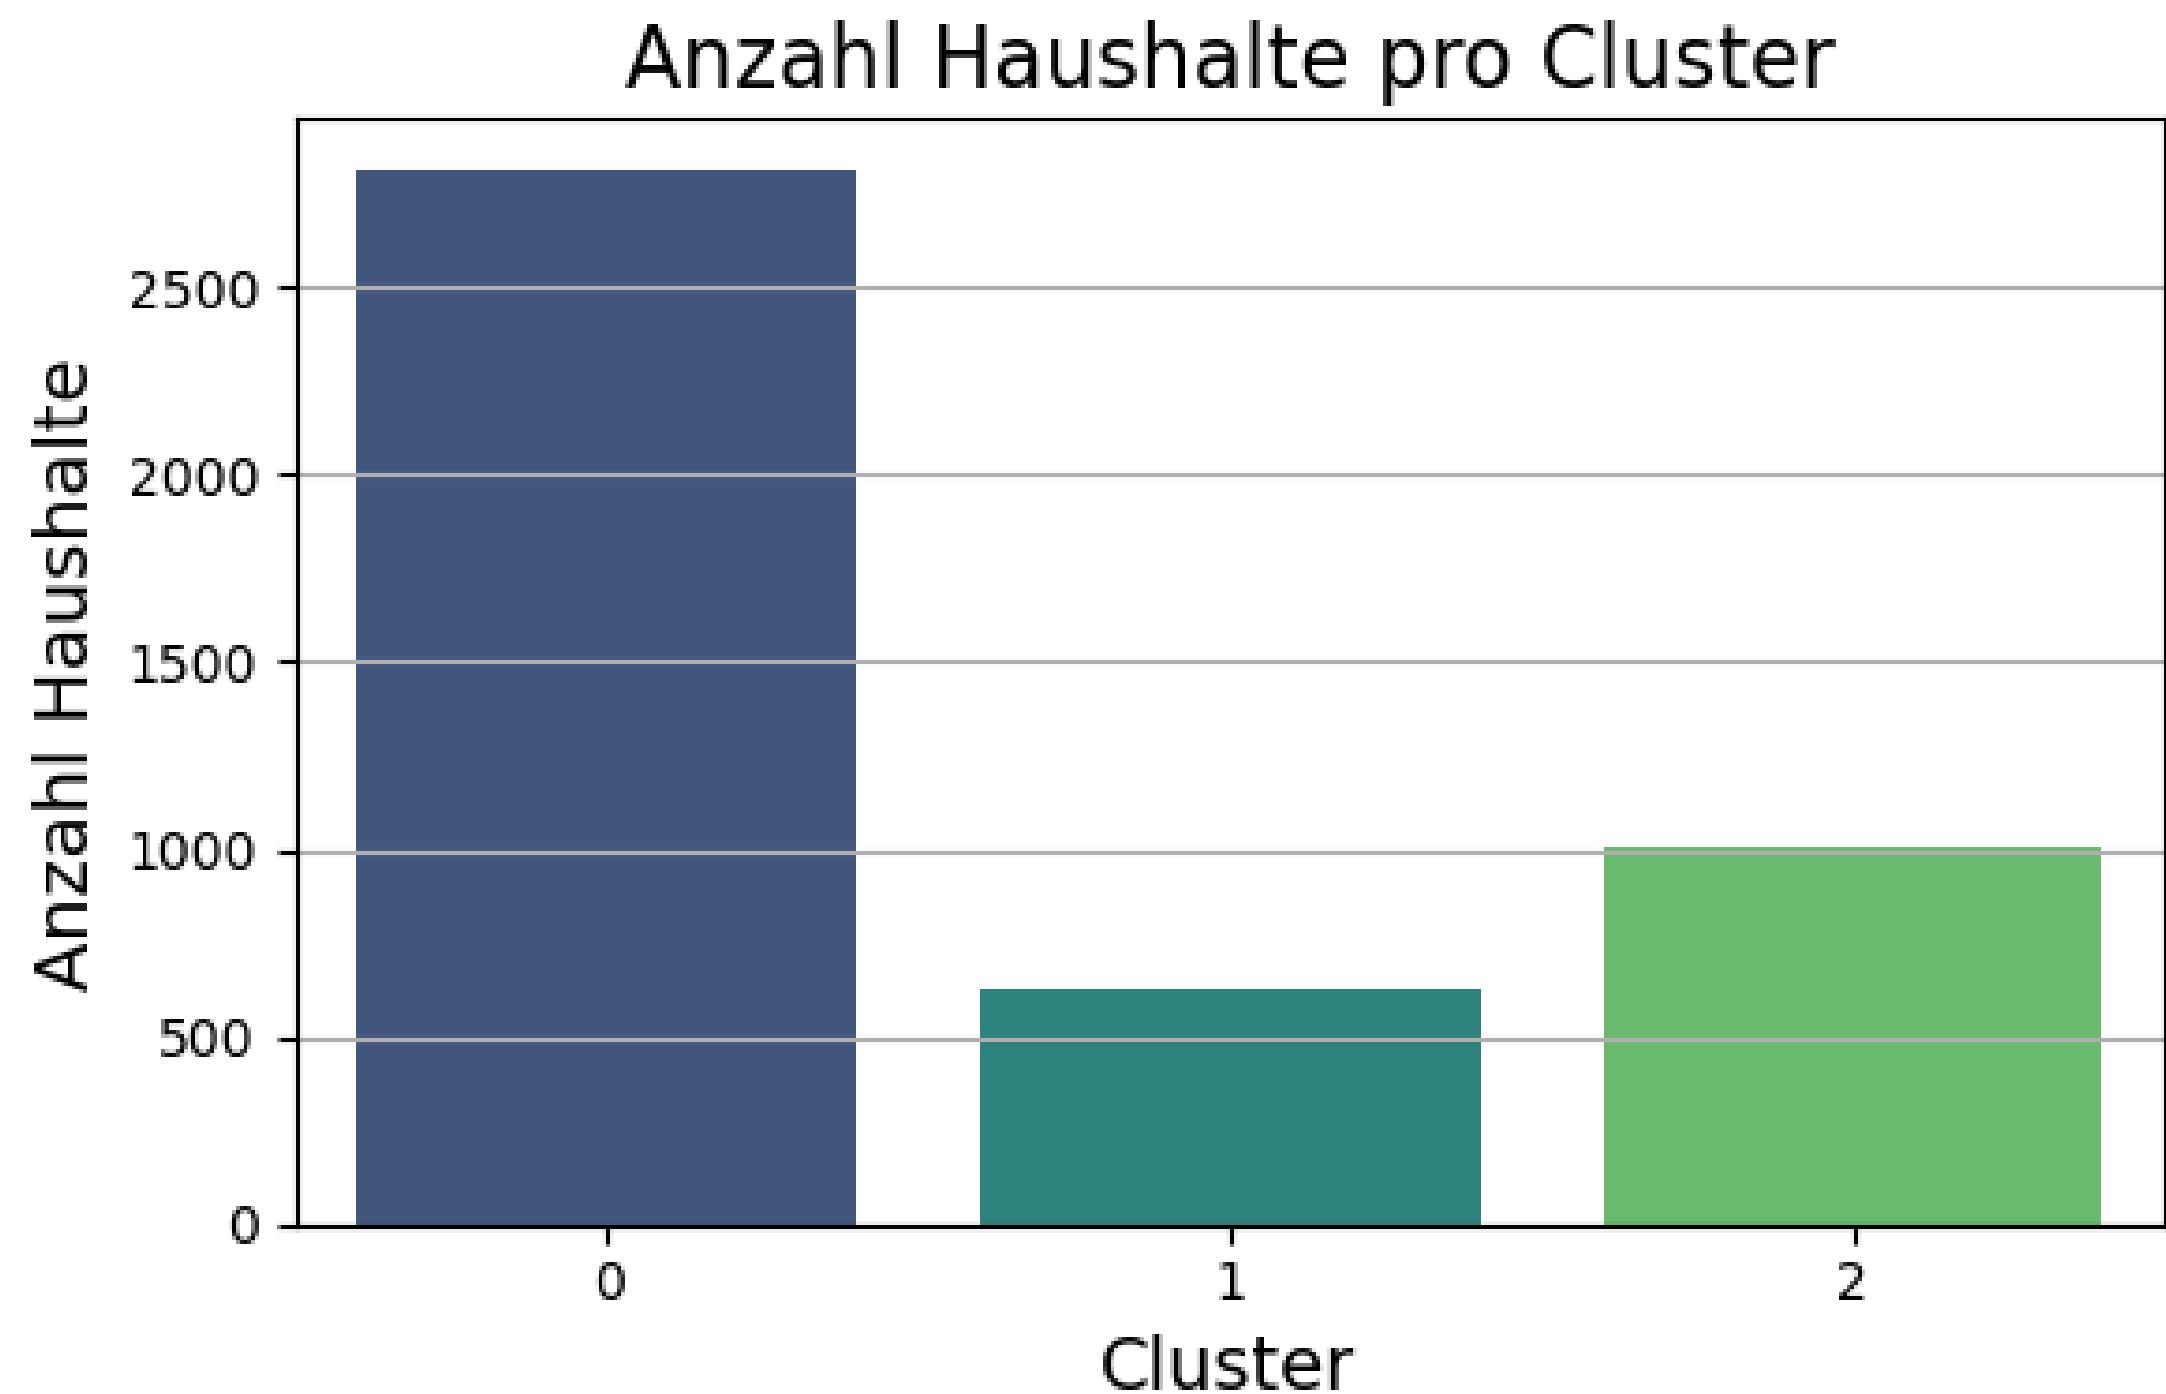
Cluster 0	Cluster 1	Cluster 2
<ul style="list-style-type: none">• Häufige Nutzung der Geräte / App• Regelmäßige Käufe mit mittlerem Umsatz• Hohe Zufriedenheit	<ul style="list-style-type: none">• Extrem intensive Nutzung der App• Höchster Umsatz durch In-App-Käufe• Zufriedenheit solide, aber nicht überdurchschnittlich	<ul style="list-style-type: none">• Kaum Nutzung von Geräten / App• Sehr wenige Käufe, niedriger Umsatz• Niedrigste Zufriedenheit
→ Ideale Zielgruppe für gezielte Angebote und Cross-Selling	→ VIP-Programme und Serviceverbesserungen können Loyalität und Zufriedenheit steigern	→ Zielgruppe für Aktivierungsmaßnahmen, Onboarding und Support

Ergebnisse des Clustering

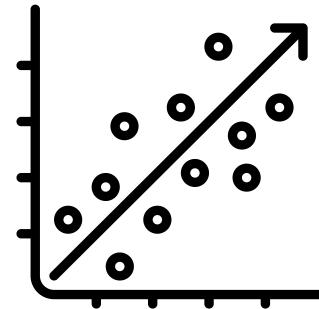


- Deutliche Abgrenzung des passiven Clusters von den beiden aktiven Clustern
- Teilweise Überlappung zwischen Clustern der aktiven Nutzer → reflektiert Verhaltensähnlichkeiten
- Klare Positionierung der Clusterzentren → bestätigt Differenzierung der Segmente

Ergebnisse des Clustering



Auswahl der Modellierungsarten



Regression

Analyse der Performance der Geräte

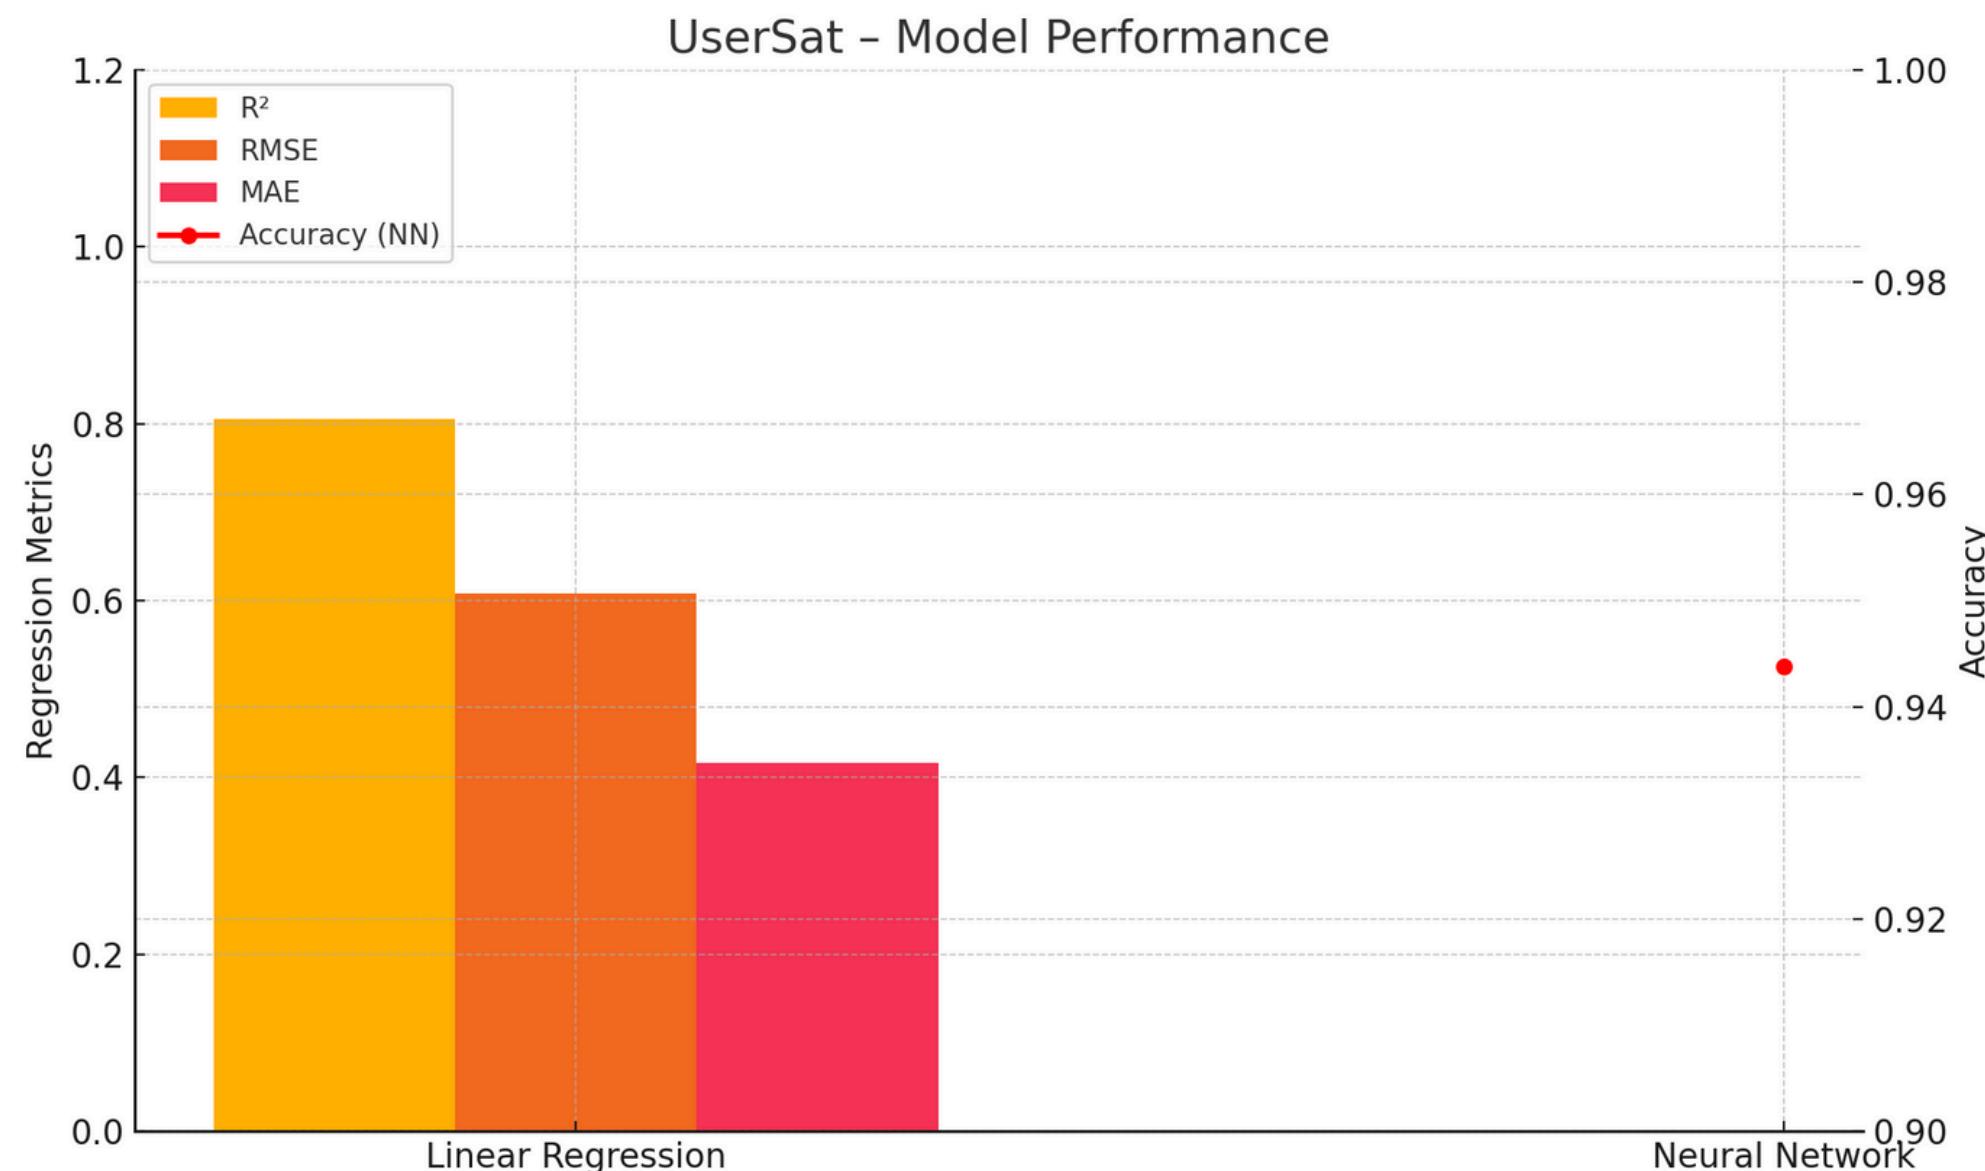
Business Frage: Welche Geräte haben den grössten Einfluss?

Nutzen: Erkennen, in welche Produktreihe sich Investitionen lohnen

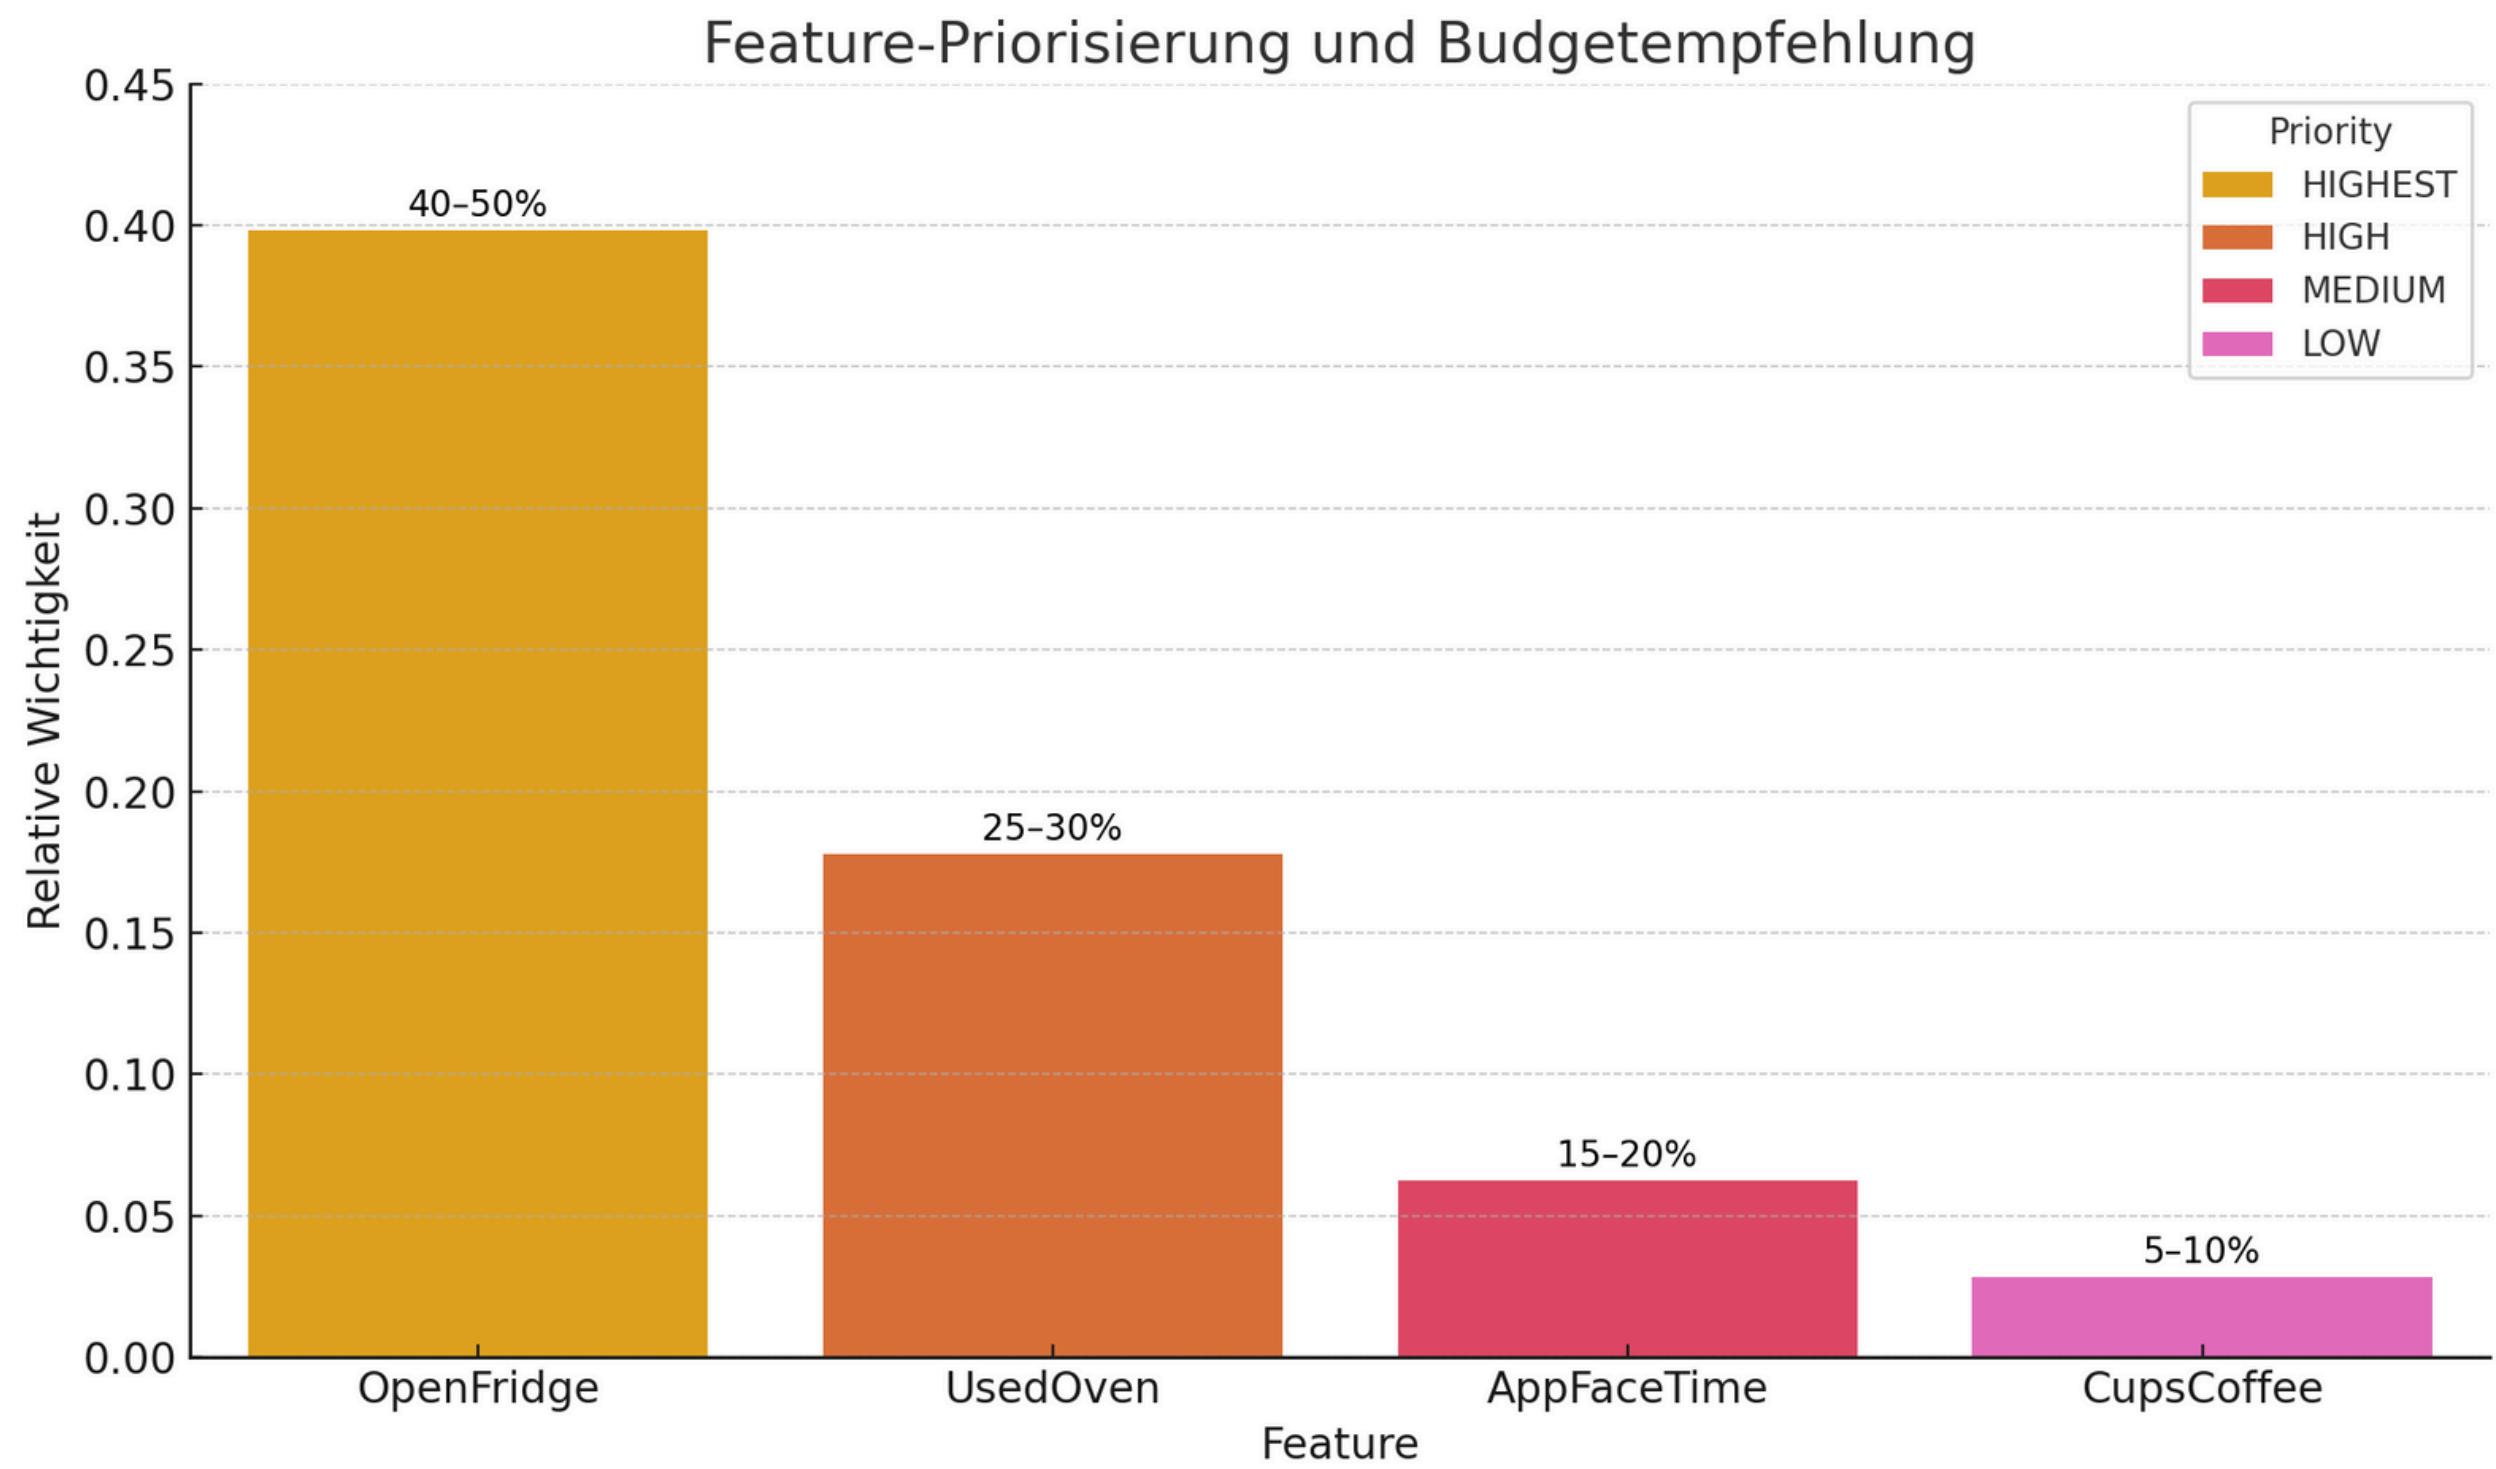
Ergebnisse des Regression

Zielvariablen: InAppPurchase, 'UserSat', 'NPS'

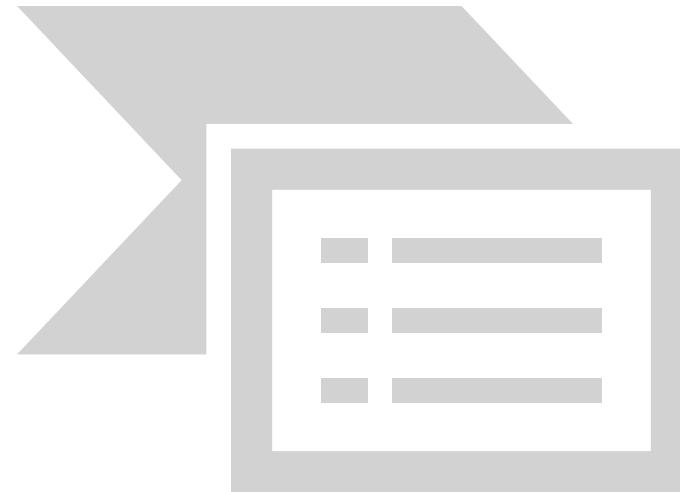
Features: 'CupsCoffee', 'UsedOven', 'OpenFridge', 'AppFacetime'



Ergebnisse des Regression



Einsatz im Unternehmen



Gezieltes Marketing:

Haushalte mit hoher Kaufbereitschaft können direkt angesprochen werden
→ höhere Conversion & effizientere Kampagnen

Segmentbasiertes Handeln:

Unterschiedliche Nutzersegmente (z.B. Power-User, Passive Nutzer) ermöglichen differenzierte Strategien in Marketing, Produktentwicklung und Kundenservice

Recommendation

Recommendation



Vorhersage der Zufriedenheit zur Empfehlungssaußpielung

Business Frage: Welche Geräte haben den grössten Einfluss?

Nutzen: Vorhersage der UserSat-Wertes auf Basis von Nutzerverhalten, Geräteverwendung und Kaufverhalten

Recommendation

Relevante Erkenntnisse:

- Der smarte Kühlschrank hat den größten Einfluss auf Käufe, Zufriedenheit und Nutzerbindung.
- Power-User kaufen viel, sind aber nicht automatisch zufrieden – Risiko für Abwanderung.
- Niedrige App-Nutzung ist ein klarer Indikator für sinkende Zufriedenheit.
- Zufriedenheit lässt sich vorhersagen – und frühzeitig negativ beeinflusste Nutzer identifizieren.
- Nutzersegmente unterscheiden sich deutlich – gezielte Ansprache ist notwendig.

Recommendation

Strategische Empfehlungen:

Fridge-first Strategie

- Ausbau smarter Kühlschranksfunktionen wie automatische Einkaufslisten & Rezeptvorschläge.

Personalisierte In-App-Empfehlungen

- Dynamische Tipps basierend auf Nutzung und Zufriedenheitsprognosen (z.B. „Neue Kaffeeaktion entdecken“).

Segmentbasiertes Nutzer-Targeting

- Upselling bei zufriedenen Käufern, Bindung bei Power-Usern, Aktivierung bei passiven Nutzern.

Frühwarnsystem für Unzufriedenheit

- Automatische Erkennung und Reaktion über die App bei abfallender Zufriedenheit.

Datengetriebene Geräteentwicklung

- Investitionen fokussiert auf Geräte mit hohem Einfluss auf Kaufverhalten und Zufriedenheit (z.B. Fridge).

Fazit:

Die Kombination aus Geräteperformance, Segmentierung und Zufriedenheitsprognose ermöglicht eine gezielte Weiterentwicklung der Home Connect App – mit dem Ziel: höherer Umsatz, stärkere Bindung und zufriedenere Nutzer.

Statement of work

Projektmitglied	Aufgabenbeschreibung
Selcuk Balikci	Vorbereitung & Datenvorbereitung, Datenexploration, Business Understanding, Modeling, PPT
Jan Müller	Vorbereitung & Datenvorbereitung, Datenexploration, Business Understanding, Modeling, PPT
Glen Braun	Vorbereitung & Datenvorbereitung, Datenexploration, Business Understanding, Modeling, PPT
Nuri Saracoglu	Vorbereitung & Datenvorbereitung, Datenexploration, Business Understanding, Modeling, PPT
Liv Rottler	Vorbereitung & Datenvorbereitung, Datenexploration, Business Understanding, Modeling, PPT
Hatun-Nur Karaca	Vorbereitung & Datenvorbereitung, Datenexploration, Business Understanding, Modeling, PPT

Vielen Dank !

DBE25-Artificial Intelligence

Gruppe 4

Hatun-Nur Karaca, 814149

Jan Müller, 816574

Selcuk Balikci, 813401

Liv Rottler, 816652

Nuri Saracoglu, 814492

Glen Braun, 816364

